

# ความรู้เบื้องต้นเกี่ยวกับปัญญาประดิษฐ์

บรรยายครั้งที่ 6: การให้เหตุผลข้ามเวลา


ผศ. ดร. อิทธิพล พ่องแก้ว  
[ittipon@g.sut.ac.th](mailto:ittipon@g.sut.ac.th)




# วันนี้

คงสถานะความเชื่อ (belief state) เกี่ยวกับโลก และอัปเดตเมื่อเวลาผ่านไปและมีหลักฐานใหม่เข้ามา

- แบบจำลองมาร์คอฟ (Markov models)
  - กระบวนการมาร์คอฟ (Markov processes)
  - งานการอนุมาน (Inference tasks)
  - แบบจำลองมาร์คอฟแบบซ่อนเร้น (Hidden Markov models)
- ตัวกรอง (Filters)
  - ตัวกรองคัลมาณ (Kalman filter)
  - ตัวกรองอนุภาค (Particle filter)



อย่ามองข้ามการบรรยายนี้!



Pacman แก้แค้น: จะใช้ประโยชน์จากค่าที่อ่านได้จากโซนารีได้อย่างไร?

## แบบจำลองมาร์คอฟ (Markov models)

## การสร้างแบบจำลองการเปลี่ยนแปลงของเวลา

เราจะพิจารณาโลกว่าเป็นชุดของช่วงเวลาที่ **ไม่ต่อเนื่อง** (discrete) ซึ่งแต่ละช่วงเวลาประกอบด้วยชุดของตัวแปรสุ่ม:

- $\mathbf{X}_t$  แทนเซตของตัวแปรสถานะที่ **ไม่สามารถสังเกตได้** (unobservable) ณ เวลา  $t$
- $\mathbf{E}_t$  แทนเซตของตัวแปรหลักฐานที่ **สามารถสังเกตได้** (observable) ณ เวลา  $t$

## เราจะระบุ

- ค่าก่อน (prior)  $P(\mathbf{X}_0)$  ที่กำหนดสถานะความเชื่อเริ่มต้นของเรามากับตัวแปรสถานะที่ซ่อนอยู่
- แบบจำลองการเปลี่ยนสถานะ (transition model)  $P(\mathbf{X}_t|\mathbf{X}_{0:t-1})$  (สำหรับ  $t > 0$ ) ที่กำหนดการแจกแจงความน่าจะเป็นของตัวแปรสถานะล่าสุด โดยพิจารณาจากค่าก่อนหน้า (ที่ไม่ได้สังเกต)
- แบบจำลองเซ็นเซอร์ (sensor model)  $P(\mathbf{E}_t|\mathbf{X}_{0:t}, \mathbf{E}_{0:t-1})$  (สำหรับ  $t > 0$ ) ที่กำหนดการแจกแจงความน่าจะเป็นของตัวแปรหลักฐานล่าสุด โดยพิจารณาจากค่าก่อนหน้าทั้งหมด (ทั้งที่สังเกตได้และไม่ได้สังเกต)

## กระบวนการมาร์คอฟ (Markov processes)

### ข้อสมมติของมาร์คอฟ (Markov assumption)

สถานะปัจจุบันของ โลกขึ้นอยู่กับสถานะก่อนหน้าทันทีเท่านั้น กล่าวคือ  $\mathbf{X}_t$  ขึ้นอยู่กับเซตย่ออย่างที่มีขอบเขตของ  $\mathbf{X}_{0:t-1}$  เท่านั้น

กระบวนการลุ่มที่สอดคล้องกับข้อสมมตินี้เรียกว่า **กระบวนการมาร์คอฟ (Markov processes)** หรือ **ลูกโซ่มาร์คอฟ (Markov chains)**

### กระบวนการมาร์คอฟอันดับหนึ่ง (First-order Markov processes)

กระบวนการมาร์คอฟที่

$$P(\mathbf{X}_t | \mathbf{X}_{0:t-1}) = P(\mathbf{X}_t | \mathbf{X}_{t-1})$$

กล่าวคือ  $\mathbf{X}_t$  และ  $\mathbf{X}_{0:t-2}$  เป็นอิสระต่อกันตามเงื่อนไข (conditionally independent) เมื่อกำหนด  $\mathbf{X}_{t-1}$



### ข้อสมมติของเซ็นเซอร์มาคอฟ (Sensor Markov assumption)


เราตั้งข้อสมมติของเซ็นเซอร์มาคอฟ (อันดับหนึ่ง) ว่า

$$P(E_t | X_{0:t}, E_{0:t-1}) = P(E_t | X_t)$$

### ข้อสมมติของความนิ่ง (Stationarity assumption)

แบบจำลองการเปลี่ยนสถานะและแบบจำลองเซ็นเซอร์จะเหมือนกันสำหรับทุกค่า  $t$  (กล่าวคือ กฎทางพลิกไม่เปลี่ยนแปลงตามเวลา)

## การแจกแจงร่วม (Joint distribution)





ลูกโซ้มาร์คوفที่เชื่อมต่อกันแบบจำลองเชิงเชอร์สามารถแสดงเป็นเครือข่ายแบบเบย์ (Bayesian network) ที่ **ขยายได้** (growable) และคลื่อๆ ไปอย่างไม่สิ้นสุดตามเวลา


การแจกแจงร่วมของตัวแปรทั้งหมดจนถึงเวลา  $t$  คือ

$$P(\mathbf{X}_{0:t}, \mathbf{E}_{1:t}) = P(\mathbf{X}_0) \prod_{i=1}^t P(\mathbf{X}_i | \mathbf{X}_{i-1}) P(\mathbf{E}_i | \mathbf{X}_i)$$

ตัวอย่าง: วันนี้คุณจะพก傘ไปด้วยไหม?



- $P(\text{Umbrella}_t | \text{Rain}_t)$ ?
- $P(\text{Rain}_t | \text{Umbrella}_{0:t-1})$ ?
- $P(\text{Rain}_{t+2} | \text{Rain}_t)$ ?





แบบจำลองการเปลี่ยนสถานะ  $P(\text{Rain}_t | \text{Rain}_{t-1})$  สามารถแสดงแทนได้ด้วยแผนภาพการเปลี่ยนสถานะ (state transition diagram)

## งานการอนุมาน (Inference tasks)

- การทำนาย (Prediction):  $P(\mathbf{X}_{t+k}|\mathbf{e}_{1:t})$  สำหรับ  $k > 0$ 
  - การคำนวณการแจกแจงภายหลัง (posterior distribution) ของสถานะในอนาคต
  - ใช้สำหรับการประเมินลำดับการกระทำที่เป็นไปได้
- การกรอง (Filtering):  $P(\mathbf{X}_t|\mathbf{e}_{1:t})$ 
  - การกรองศักยภาพลี่ที่เอเจนต์ที่มีเหตุผล (rational agent) ทำเพื่อติดตามสถานะที่ซ่อนอยู่ปัจจุบัน  $\mathbf{X}_t$  หรือ **สถานะความเชื่อ (belief state)** ของมัน เพื่อให้สามารถตัดสินใจอย่างมีเหตุผลได้
- การปรับให้เรียบ (Smoothing):  $P(\mathbf{X}_k|\mathbf{e}_{1:t})$  สำหรับ  $0 \leq k < t$ 
  - การคำนวณการแจกแจงภายหลังของสถานะในอดีต
  - ใช้เพื่อสร้างการประมาณค่าที่ดีขึ้น เนื่องจากรวมหลักฐานมากขึ้น
  - จำเป็นสำหรับการเรียนรู้
- คำอธิบายที่น่าจะเป็นไปได้มากที่สุด (Most likely explanation):  $\arg \max_{\mathbf{x}_{1:t}} P(\mathbf{x}_{1:t}|\mathbf{e}_{1:t})$ 
  - การคัดกรองทั้งหมดที่มีลักษณะที่มีลักษณะรูปแบบ, การรู้จำเสียงพูด, ฯลฯ

## กรณีพื้นฐาน (Base cases)




$$P(\mathbf{X}_1 | \mathbf{e}_1) = \frac{P(\mathbf{e}_1 | \mathbf{X}_1) P(\mathbf{X}_1)}{P(\mathbf{e}_1)} \\ \propto P(\mathbf{e}_1 | \mathbf{X}_1) P(\mathbf{X}_1)$$

$$P(\mathbf{X}_2) = \sum_{\mathbf{x}_1} P(\mathbf{X}_2, \mathbf{x}_1) \\ = \sum_{\mathbf{x}_1} P(\mathbf{x}_1) P(\mathbf{X}_2 | \mathbf{x}_1)$$

(อัปเดต) อัปเดต  $P(\mathbf{X}_1)$  ด้วยหลักฐาน  $\mathbf{e}_1$  โดยใช้แบบจำลอง เชิงเชอร์

(ทำนาย) ผลัก  $P(\mathbf{X}_1)$  ไปข้างหน้าผ่านแบบจำลองการเปลี่ยนสถานะ

## การทำนาย (Prediction)



เพื่อทำนายอนาคต  $\mathbf{P}(\mathbf{X}_{t+k}|\mathbf{e}_{1:t})$ :

- ผลักสถานะความเชื่อก่อนหน้า  $\mathbf{P}(\mathbf{X}_t|\mathbf{e}_{1:t})$  ผ่านแบบจำลองการเปลี่ยนสถานะ:

$$\mathbf{P}(\mathbf{X}_{t+1}|\mathbf{e}_{1:t}) = \sum_{\mathbf{x}_t} \mathbf{P}(\mathbf{X}_{t+1}|\mathbf{x}_t) \mathbf{P}(\mathbf{x}_t|\mathbf{e}_{1:t})$$

- ทำข้างในถึง  $t+k$  โดยใช้  $\mathbf{P}(\mathbf{X}_{t+k-1}|\mathbf{e}_{1:t})$  เพื่อคำนวณ  $\mathbf{P}(\mathbf{X}_{t+k}|\mathbf{e}_{1:t})$

0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02

GHOSTS REMAINING: 1  
BUSTS REMAINING: 1  
SCORE: 0

MESSAGES:

BUST  
TIME+1

⋮

ผลวัดแบบสุ่ม (Random dynamics)

0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02

GHOSTS REMAINING: 1  
BUSTS REMAINING: 1  
SCORE: 0

MESSAGES:

BUST  
TIME+1

⋮

พลวัตแบบวงกลม (Circular dynamics)

0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02
0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02	0.02

GHOSTS REMAINING: 1  
BUSTS REMAINING: 1  
SCORE: 0

MESSAGES:

BUST  
TIME+1

⋮

พลวัตแบบน้ำวน (Whirlpool dynamics)

<0.01	<0.01	<0.01	<0.01	<0.01	<0.01
<0.01	<0.01	<0.01	<0.01	<0.01	<0.01
<0.01	<0.01	1.00	<0.01	<0.01	<0.01
<0.01	<0.01	<0.01	<0.01	<0.01	<0.01

T = 1

<0.01	<0.01	<0.01	<0.01	<0.01	<0.01
<0.01	<0.01	0.06	<0.01	<0.01	<0.01
<0.01	0.76	0.06	0.06	<0.01	<0.01
<0.01	<0.01	0.06	<0.01	<0.01	<0.01

T = 2

...

0.05	0.01	0.05	<0.01	<0.01	<0.01
0.02	0.14	0.11	0.35	<0.01	<0.01
0.07	0.03	0.05	<0.01	0.03	<0.01
0.03	0.03	<0.01	<0.01	<0.01	<0.01

T = 5



เมื่อเวลาผ่านไป ความไม่แน่นอน (uncertainty) มักจะเพิ่มขึ้นเมื่อไม่มีหลักฐานใหม่

## การแจกแจงคงที่ (Stationary distributions)

จะเกิดอะไรขึ้นถ้า  $t \rightarrow \infty$ ?

- สำหรับลูกโซ่ส่วนใหญ่ อิทธิพลของการแจกแจงเริ่มต้นจะลดน้อยลงเรื่อยๆ ตามเวลา
- ในที่สุด การแจกแจงจะลู่เข้าสู่จุดคงที่ เรียกว่า **การแจกแจงคงที่** (stationary distribution)
- การแจกแจงนี้เป็นไปตามสมการ

$$\mathbf{P}(\mathbf{X}_\infty) = \mathbf{P}(\mathbf{X}_{\infty+1}) = \sum_{\mathbf{x}_\infty} \mathbf{P}(\mathbf{X}_{\infty+1}|\mathbf{x}_\infty) P(\mathbf{x}_\infty)$$

$\mathbf{X}_{t-1}$	$\mathbf{X}_t$	$P$
sun	sun	0.9
sun	rain	0.1
rain	sun	0.3
rain	rain	0.7

### ตัวอย่าง

$$\begin{aligned}
 P(\mathbf{X}_\infty = \text{sun}) &= P(\mathbf{X}_{\infty+1} = \text{sun}) \\
 &= P(\mathbf{X}_{\infty+1} = \text{sun} | \mathbf{X}_\infty = \text{sun})P(\mathbf{X}_\infty = \text{sun}) \\
 &\quad + P(\mathbf{X}_{\infty+1} = \text{sun} | \mathbf{X}_\infty = \text{rain})P(\mathbf{X}_\infty = \text{rain}) \\
 &= 0.9P(\mathbf{X}_\infty = \text{sun}) + 0.3P(\mathbf{X}_\infty = \text{rain})
 \end{aligned}$$

ดังนั้น  $P(\mathbf{X}_\infty = \text{sun}) = 3P(\mathbf{X}_\infty = \text{rain})$

ซึ่งหมายความว่า  $P(\mathbf{X}_\infty = \text{sun}) = \frac{3}{4}$  และ  $P(\mathbf{X}_\infty = \text{rain}) = \frac{1}{4}$

## การกรอง (Filtering)

0.05	0.01	0.05	<0.01	<0.01	<0.01
0.02	0.14	0.11	0.35	<0.01	<0.01
0.07	0.03	0.05	<0.01	0.03	<0.01
0.03	0.03	<0.01	<0.01	<0.01	<0.01

Before observation

<0.01	<0.01	<0.01	<0.01	0.02	<0.01
<0.01	<0.01	<0.01	0.83	0.02	<0.01
<0.01	<0.01	0.11	<0.01	<0.01	<0.01
<0.01	<0.01	<0.01	<0.01	<0.01	<0.01

After observation

เมื่อมีหลักฐานใหม่ ความไม่แน่นอนจะลดลง ความเชื่อจะถูกถ่วงน้ำหนักใหม่ แต่อย่างไร?

## ตัวกรองของเบย์ (Bayes filter)

เอเจนต์จะรักษาการประมาณค่า **สถานะความเชื่อ** (belief state)  $P(\mathbf{X}_t | \mathbf{e}_{1:t})$  และอัปเดตเมื่อมีหลักฐานใหม่  $\mathbf{e}_{t+1}$  เข้ามา

กระบวนการนี้สามารถทำได้โดยใช้กระบวนการการประมาณค่าแบบเบย์เรียนรู้  $\mathbf{P}(\mathbf{X}_{t+1} | \mathbf{e}_{1:t+1}) = f(\mathbf{e}_{t+1}, \mathbf{P}(\mathbf{X}_t | \mathbf{e}_{1:t}))$  ซึ่งสับเปลี่ยนกับกระบวนการที่ใช้ในหัวข้อที่แล้ว

- (ขั้นตอนการทำนาย): ฉายภาพสถานะความเชื่อปัจจุบันไปข้างหน้าจาก  $t$  ไปยัง  $t + 1$  ผ่านแบบจำลองการเปลี่ยนสถานะ
- (ขั้นตอนการอัปเดต): อัปเดตสถานะใหม่โดยใช้หลักฐาน  $\mathbf{e}_{t+1}$

ในทางคณิตศาสตร์ ตัวกรองของเบย์ถูกกำหนดโดย

$$\begin{aligned}\mathbf{P}(\mathbf{X}_{t+1}|\mathbf{e}_{1:t+1}) &= \mathbf{P}(\mathbf{X}_{t+1}|\mathbf{e}_{1:t}, \mathbf{e}_{t+1}) \\ &\propto \mathbf{P}(\mathbf{e}_{t+1}|\mathbf{X}_{t+1}, \mathbf{e}_{1:t})\mathbf{P}(\mathbf{X}_{t+1}|\mathbf{e}_{1:t}) \\ &\propto \mathbf{P}(\mathbf{e}_{t+1}|\mathbf{X}_{t+1})\mathbf{P}(\mathbf{X}_{t+1}|\mathbf{e}_{1:t}) \\ &\propto \mathbf{P}(\mathbf{e}_{t+1}|\mathbf{X}_{t+1}) \sum_{\mathbf{x}_t} \mathbf{P}(\mathbf{X}_{t+1}|\mathbf{x}_t, \mathbf{e}_{1:t})P(\mathbf{x}_t|\mathbf{e}_{1:t}) \\ &\propto \mathbf{P}(\mathbf{e}_{t+1}|\mathbf{X}_{t+1}) \sum_{\mathbf{x}_t} \mathbf{P}(\mathbf{X}_{t+1}|\mathbf{x}_t)P(\mathbf{x}_t|\mathbf{e}_{1:t})\end{aligned}$$

โดยที่

- ค่าคงที่การทำให้เป็นบรรทัดฐาน (normalization constant)

$$Z = P(\mathbf{e}_{t+1}|\mathbf{e}_{1:t}) = \sum_{\mathbf{x}_{t+1}} P(\mathbf{e}_{t+1}|\mathbf{x}_{t+1})P(\mathbf{x}_{t+1}|\mathbf{e}_{1:t})$$


ใช้เพื่อทำให้ความน่าจะเป็นรวมกันเป็น 1

- ในนิพจน์สุดท้าย พจน์แรกและพจน์ที่สองได้มาจากการจำลอง ในขณะที่พจน์ที่สามได้มาจากการเรียกซ้ำ

เราสามารถคิดว่า  $P(\mathbf{X}_t | \mathbf{e}_{1:t})$  เป็น ข้อความ (message)  $\mathbf{f}_{1:t}$  ที่ถูกส่งต่อ ไปข้างหน้า (forward) ตามลำดับ ซึ่งถูกแก้ไข โดยการเปลี่ยนสถานะแต่ละครั้งและอัปเดต โดยการสังเกตใหม่แต่ละครั้ง

ดังนั้น กระบวนการนี้สามารถเขียนเป็น  $\mathbf{f}_{1:t+1} \propto \text{forward}(\mathbf{f}_{1:t}, \mathbf{e}_{t+1})$  ความซับซ้อนของมันคงที่ (ทั้ง ในด้านเวลาและพื้นที่) เทียบกับ  $t$

## ตัวอย่าง



$$R_{t-1} P(R_t)$$


true 0.7

false 0.3


$$R_t P(U_t)$$

true 0.9

false 0.2



Ghostbusters กับตัวกรองของเบย์



ghostbusters

### Ghostbusters กับตัวกรองของเบย์

```
python3 run.py --nghosts 2 --layout maze_small --agentfile sherlockpacman.py --bsagentfile bayesfilter.py --show True  
python3 run.py --nghosts 3 --layout maze_medium --agentfile sherlockpacman.py --bsagentfile bayesfilter.py --show True  
python3 run.py --nghosts 4 --layout maze_huge --agentfile sherlockpacman.py --bsagentfile bayesfilter.py --show True
```

## การปรับให้เรียบ (Smoothing)

เราต้องการคำนวณ  $\mathbf{P}(\mathbf{X}_k | \mathbf{e}_{1:t})$  สำหรับ  $0 \leq k < t$

โดยการแบ่งหลักฐาน  $\mathbf{e}_{1:t}$  ออกเป็น  $\mathbf{e}_{1:k}$  และ  $\mathbf{e}_{k+1:t}$  เราจะได้

$$\begin{aligned}\mathbf{P}(\mathbf{X}_k | \mathbf{e}_{1:t}) &= \mathbf{P}(\mathbf{X}_k | \mathbf{e}_{1:k}, \mathbf{e}_{k+1:t}) \\ &\propto \mathbf{P}(\mathbf{X}_k | \mathbf{e}_{1:k}) \mathbf{P}(\mathbf{e}_{k+1:t} | \mathbf{X}_k, \mathbf{e}_{1:k}) \\ &\propto \mathbf{P}(\mathbf{X}_k | \mathbf{e}_{1:k}) \mathbf{P}(\mathbf{e}_{k+1:t} | \mathbf{X}_k)\end{aligned}$$

ให้ข้อความ **ข้อนกลับ** (backward)  $\mathbf{b}_{k+1:t}$  แทน  $\mathbf{P}(\mathbf{e}_{k+1:t}|\mathbf{X}_k)$  ดังนั้น

$$\mathbf{P}(\mathbf{X}_k|\mathbf{e}_{1:t}) = \alpha \mathbf{f}_{1:k} \times \mathbf{b}_{k+1:t},$$

โดยที่  $\times$  คือการคูณแบบจุดต่อจุดของเวกเตอร์

ข้อความข้อนกลับนี้สามารถคำนวณได้โดยใช้การเรียกข้ามแบบข้อนกลับ:

$$\begin{aligned}\mathbf{P}(\mathbf{e}_{k+1:t}|\mathbf{X}_k) &= \sum_{\mathbf{x}_{k+1}} \mathbf{P}(\mathbf{e}_{k+1:t}|\mathbf{X}_k, \mathbf{x}_{k+1}) \mathbf{P}(\mathbf{x}_{k+1}|\mathbf{X}_k) \\ &= \sum_{\mathbf{x}_{k+1}} P(\mathbf{e}_{k+1:t}|\mathbf{x}_{k+1}) \mathbf{P}(\mathbf{x}_{k+1}|\mathbf{X}_k) \\ &= \sum_{\mathbf{x}_{k+1}} P(\mathbf{e}_{k+1}|\mathbf{x}_{k+1}) P(\mathbf{e}_{k+2:t}|\mathbf{x}_{k+1}) \mathbf{P}(\mathbf{x}_{k+1}|\mathbf{X}_k)\end{aligned}$$

ปัจจัยแรกและปัจจัยสุดท้ายได้มาจากการคำนวณ ปัจจัยที่สองได้มาจากการเรียกช้า ดังนั้น

$$\mathbf{b}_{k+1:t} = \text{backward}(\mathbf{b}_{k+2:t}, \mathbf{e}_{k+1})$$

## อัลกอริทึมไปข้างหน้า-ย้อนกลับ (Forward-backward algorithm)


```
function FORWARD-BACKWARD(ev, prior) returns a vector of probability distributions
    inputs: ev, a vector of evidence values for steps 1, ..., t
            prior, the prior distribution on the initial state, P(X₀)
    local variables: fv, a vector of forward messages for steps 0, ..., t
                    b, a representation of the backward message, initially all 1s
                    sv, a vector of smoothed estimates for steps 1, ..., t

    fv[0] ← prior
    for i = 1 to t do
        fv[i] ← FORWARD(fv[i - 1], ev[i])
    for i = t downto 1 do
        sv[i] ← NORMALIZE(fv[i] × b)
        b ← BACKWARD(b, ev[i])
    return sv
```

ความซับซ้อน:

- การปรับให้เรียบสำหรับช่วงเวลา  $k$  ไดๆ ในเวลา:  $O(t)$
- การปรับให้เรียบทั้งหมด (เนื่องจากการแคนช์):  $O(t)$

## ตัวอย่าง



## คำอธิบายที่น่าจะเป็นไปได้มากที่สุด (Most likely explanation)





สมมติว่า [true, true, false, true, true] คือลำดับการพกร่ม

- ลำดับของสภาพอากาศที่น่าจะอธิบายลิ้งนี้ได้ดีที่สุดคืออะไร?
- ในบรรดาลำดับทั้งหมด 2<sup>5</sup> ลำดับ มีวิธี (ที่มีประสิทธิภาพ) ในการค้นหาลำดับที่น่าจะเป็นไปได้มากที่สุดหรือไม่?

ลำดับที่น่าจะเป็นไปได้มากที่สุด  $\text{ไม่ใช่}$  ลำดับของสถานะที่น่าจะเป็นไปได้มากที่สุด!

เส้นทางที่น่าจะเป็นไปได้มากที่สุดไปยังแต่ละ  $\mathbf{x}_{t+1}$  คือเส้นทางที่น่าจะเป็นไปได้มากที่สุดไปยัง บาง  $\mathbf{x}_t$  มากอีกหนึ่งขั้นตอน ดังนั้น

$$\begin{aligned} & \max_{\mathbf{x}_{1:t}} \mathbf{P}(\mathbf{x}_{1:t}, \mathbf{X}_{t+1} | \mathbf{e}_{1:t+1}) \\ & \propto \mathbf{P}(\mathbf{e}_{t+1} | \mathbf{X}_{t+1}) \max_{\mathbf{x}_t} (\mathbf{P}(\mathbf{X}_{t+1} | \mathbf{x}_t) \max_{\mathbf{x}_{1:t-1}} \mathbf{P}(\mathbf{x}_{1:t-1}, \mathbf{x}_t | \mathbf{e}_{1:t})) \end{aligned}$$

ลองพิจารณาเส้นทางที่ไปถึงสถานะ Rain = true

เนื่องจากคุณสมบัติของมาร์คอฟ จะเห็นได้ว่าเส้นทางที่น่าจะเป็นไปได้มากที่สุดไปยังสถานะ Rain = true ประกอบด้วยเส้นทางที่น่าจะเป็นไปได้มากที่สุดไปยังสถานะใดสถานะหนึ่ง ณ เวลา 4 ตามด้วยการเปลี่ยนไปยัง Rain = true; และสถานะ ณ เวลา 4 ที่จะกลายเป็นส่วนหนึ่งของเส้นทางไปยัง Rain = true คือสถานะใดก็ตามที่ทำให้ความน่าจะเป็นของเส้นทางนั้นสูงสุด

ลิ่งนี้เหมือนกับการกรอง ยกเว้นว่า

- ข้อความไปข้างหน้า  $\mathbf{f}_{1:t} = \mathbf{P}(\mathbf{X}_t | \mathbf{e}_{1:t})$  ถูกแทนที่ด้วย

$$\mathbf{m}_{1:t} = \max_{\mathbf{x}_{1:t-1}} \mathbf{P}(\mathbf{x}_{1:t-1}, \mathbf{X}_t | \mathbf{e}_{1:t}),$$

โดยที่  $\mathbf{m}_{1:t}(i)$  ให้ความน่าจะเป็นของเส้นทางที่น่าจะเป็นไปได้มากที่สุดไปยังสถานะ  $i$

- การอัปเดตมีการแทนที่ผลรวมด้วยค่าสูงสุด


อัลกอริทึมที่ได้เรียกว่า อัลกอริทึม Viterbi ซึ่งคำนวณคำอธิบายที่น่าจะเป็นไปได้มากที่สุดเป็น

$$\mathbf{m}_{1:t+1} \propto \mathbf{P}(\mathbf{e}_{t+1} | \mathbf{X}_{t+1}) \max_{\mathbf{x}_t} \mathbf{P}(\mathbf{X}_{t+1} | \mathbf{x}_t) \mathbf{m}_{1:t}$$

ความซับซ้อนของมันเป็นเชิงเส้นกับ  $t$  ซึ่งเป็นความยาวของลำดับ

ขั้นตอนแบบง่าย: ใช้การปรับให้เรียบเพื่อคำนวณ  $P(X_k | e_{1:t})$  จากนั้นแสดงผลลำดับของค่าที่น่าจะเป็นไปได้มากที่สุดสำหรับแต่ละ  $k$

## ตัวอย่าง



**Figure 15.5** (a) Possible state sequences for  $Rain_t$  can be viewed as paths through a graph of the possible states at each time step. (States are shown as rectangles to avoid confusion with nodes in a Bayes net.) (b) Operation of the Viterbi algorithm for the umbrella observation sequence [true, true, false, true, true]. For each  $t$ , we have shown the values of the message  $m_{1:t}$ , which gives the probability of the best sequence reaching each state at time  $t$ . Also, for each state, the bold arrow leading into it indicates its best predecessor as measured by the product of the preceding sequence probability and the transition probability. Following the bold arrows back from the most likely state in  $m_{1:5}$  gives the most likely sequence.

[Q] คุณจะตีงเส้นทางกลับมาได้อย่างไร นอกเหนือจากความน่าจะเป็นของมัน?

## แบบจำลองมาร์คอฟแบบซ่อนเร้น (Hidden Markov models)

จนถึงตอนนี้ เราได้อธิบายกระบวนการมาร์คอฟบนเซตของตัวแปรสถานะ  $\mathbf{X}_t$  และตัวแปรหลักฐาน  $\mathbf{E}_t$  ได้ฯ

- แบบจำลองมาร์คอฟแบบซ่อนเร้น (HMM) คือกระบวนการมาร์คอฟที่ทั้งสถานะ  $\mathbf{X}_t$  และหลักฐาน  $\mathbf{E}_t$  เป็นตัวแปรสุ่มเดียวกันที่ไม่ต่อเนื่อง (single discrete)
  - $\mathbf{X}_t = X_t$ , โดยมีโดเมน  $D_{X_t} = \{1, \dots, S\}$
  - $\mathbf{E}_t = E_t$ , โดยมีโดเมน  $D_{E_t} = \{1, \dots, R\}$
- โครงสร้างที่จำกัดนี้ช่วยให้สามารถปรับสูตรอัลกอริทึมไปข้างหน้า-ย้อนกลับในรูปของการดำเนินการเมทริกซ์-เวกเตอร์ได้

## หมายเหตุเกี่ยวกับคำศัพท์

ผู้เขียนบางคนแบ่งแบบจำลองมาร์คอฟออกเป็นสองประเภท ขึ้นอยู่กับการลังเกตสถานะของระบบ:

- สถานะของระบบที่ลังเกตได้: ลูกโซ่มาร์คอฟ (Markov chains)
- สถานะของระบบที่ลังเกตได้บางส่วน: แบบจำลองมาร์คอฟแบบซ่อนเร้น (Hidden Markov models)

ในที่นี้เราจะใช้คำศัพท์ตามตำราเรียนตามที่กำหนดไว้ในสไลด์ก่อนหน้า

## อัลกอริทึมเมทริกซ์แบบง่าย

- ค่าก่อน  $\mathbf{P}(\mathbf{X}_0)$  จะถูกแทนด้วยเวกเตอร์คอลัมน์ (ที่ทำให้เป็นบรรทัดฐาน)  $\mathbf{f}_0 \in \mathbb{R}_+^S$
- แบบจำลองการเปลี่ยนสถานะ  $\mathbf{P}(\mathbf{X}_t|\mathbf{X}_{t-1})$  จะถูกแทนด้วย เมทริกซ์การเปลี่ยนสถานะ (transition matrix)  $\mathbf{T}$  ขนาด  $S \times S$  โดยที่

$$\mathbf{T}_{ij} = P(X_t = j | X_{t-1} = i)$$

- แบบจำลองเซ็นเซอร์  $\mathbf{P}(\mathbf{E}_t|\mathbf{X}_t)$  ถูกกำหนดเป็น เมทริกซ์เซ็นเซอร์ (sensor matrix)  $\mathbf{B}$  ขนาด  $S \times R$  โดยที่

$$\mathbf{B}_{ij} = P(E_t = j | X_t = i)$$

- ให้เมทริกซ์การสังเกต  $\mathbf{O}_t$  เป็นเมทริกซ์ทแยงมุมที่มีสมาชิกเป็นคอลัมน์  $e_t$  ของเมทริกซ์เชิงเชอร์  $\mathbf{B}$
- ถ้าเราใช้วekเตอร์คอลัมน์แทนข้อความไปข้างหน้าและย้อนกลับ เราจะได้

$$\mathbf{f}_{1:t+1} = \alpha \mathbf{O}_{t+1} \mathbf{T}^T \mathbf{f}_{1:t}$$

$$\mathbf{b}_{k+1:t} = \mathbf{T} \mathbf{O}_{k+1} \mathbf{b}_{k+2:t},$$

โดยที่  $\mathbf{b}_{t+1:t}$  เป็นเวกเตอร์ที่มีค่าเป็นหนึ่งทั้งหมดขนาด  $S$

- ดังนั้นอัลกอริทึมไปข้างหน้า-ย้อนกลับต้องการเวลา  $O(S^2t)$  และพื้นที่  $O(St)$

## ตัวอย่าง

สมมติว่า [true, true, false, true, true] คือลำดับการพกรรุม

$$\mathbf{f}_0 = \begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix}$$

$$\mathbf{T} = \begin{pmatrix} 0.7 & 0.3 \\ 0.3 & 0.7 \end{pmatrix}$$

$$\mathbf{B} = \begin{pmatrix} 0.9 & 0.1 \\ 0.2 & 0.8 \end{pmatrix}$$

$$\mathbf{O}_1 = \mathbf{O}_2 = \mathbf{O}_4 = \mathbf{O}_5 = \begin{pmatrix} 0.9 & 0.0 \\ 0.0 & 0.2 \end{pmatrix}$$

$$\mathbf{O}_3 = \begin{pmatrix} 0.1 & 0.0 \\ 0.0 & 0.8 \end{pmatrix}$$

ดูการทำงานได้ที่ [code/lecture6-forward-backward.ipynb](#)


## การแจกแจงคงที่ (Stationary distribution)

การแจกแจงคงที่  $\mathbf{f}$  ของ HMM คือการแจกแจงที่

$$\mathbf{f} = \mathbf{T}^T \mathbf{f}$$

ดังนั้น การแจกแจงคงที่จะสอดคล้องกับเวกเตอร์ลักษณะเฉพาะ (eigenvector) (ที่ทำให้เป็นบรรทัดฐาน) ของเมทริกซ์การเปลี่ยนสถานะที่สลับเปลี่ยน (transposed) ซึ่งมีค่าลักษณะเฉพาะ (eigenvalue) เท่ากับ 1

## ตัวกรอง (Filters)



สมมติว่าเราต้องการติดตามตำแหน่งและความเร็วของหุ่นยนต์จากการสั้งเก็ตที่มีลัญญาณrgbกวนซึ่งรวมรวมเมื่อเวลาผ่านไปในทางคณิตศาสตร์ เราต้องการประมาณค่าตัวแปรสถานะต่อเนื่อง (continuous) เช่น

- ตำแหน่ง  $\mathbf{X}_t$  ของหุ่นยนต์ ณ เวลา  $t$
- ความเร็ว  $\dot{\mathbf{X}}_t$  ของหุ่นยนต์ ณ เวลา  $t$

เราสมมติว่าช่วงเวลาเป็นแบบไม่ต่อเนื่อง (discrete)

## ตัวแปรต่อเนื่อง (Continuous variables)

ให้  $X : \Omega \rightarrow D_X$  เป็นตัวแปรสุ่ม


- เมื่อ  $D_X$  เป็นอันตน์แบบนับไม่ได้ (uncountably infinite) (เช่น  $D_X = \mathbb{R}$ )  $X$  จะถูกเรียกว่า ตัวแปรสุ่มต่อเนื่อง
- ถ้า  $X$  เป็นแบบต่อเนื่องสมบูรณ์ (absolutely continuous) การแจกแจงความน่าจะเป็นของมันจะถูกอธิบายโดย พังก์ชันความหนาแน่น (density function)  $p$  ที่กำหนดความน่าจะเป็นให้กับช่วงๆ  $[a, b] \subseteq D_X$  โดยที่

$$P(a < X \leq b) = \int_a^b p(x)dx,$$

โดยที่  $p$  เป็นพังก์ชันต่อเนื่องเป็นช่วงๆ ที่ไม่เป็นลบ และ

$$\int_{D_X} p(x)dx = 1$$

## การแจกแจงเอกรูป (Uniform)




การแจกแจงเอกรูป  $U(a, b)$  ถูกอธิบายโดยพังก์ชันความหนาแน่น

$$p(x) = \begin{cases} \frac{1}{b-a} & \text{if } x \in [a, b] \\ 0 & \text{otherwise} \end{cases}$$

โดยที่  $a \in \mathbb{R}$  และ  $b \in \mathbb{R}$  คือขอบเขตของมัน

## การแจกแจงปกติ (Normal)




การแจกแจงปกติ (หรือเกาส์เซียน)  $\mathcal{N}(\mu, \sigma)$  ถูกอธิบายโดยพิงก์ชันความหนาแน่น

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma^2} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

โดยที่  $\mu \in \mathbb{R}$  และ  $\sigma \in \mathbb{R}^+$  คือพารามิเตอร์ค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐานของมัน

## การแจกแจงปกติหลายตัวแปร (Multivariate normal)



การแจกแจงปกติหลายตัวแปรขยายไปสู่ตัวแปรรุ่ม  $n$  ด้วย ฟังก์ชันความหนาแน่น (ร่วม) ของมันถูกกำหนดเป็น

$$p(\mathbf{x} = x_1, \dots, x_n) = \frac{1}{\sqrt{(2\pi)^n |\Sigma|}} \exp \left( -\frac{1}{2} (\mathbf{x} - \mathbf{m})^T \Sigma^{-1} (\mathbf{x} - \mathbf{m}) \right)$$

โดยที่  $\mathbf{m} \in \mathbb{R}^n$  และ  $\Sigma \in \mathbb{R}^{n \times n}$  เป็นเมทริกซ์บวกกึ่งแน่นอน (positive semi-definite)

## สูตรสรุปสำหรับแบบจำลองเก้าส์เชียน (Särkkä, 2013)

ถ้า  $\mathbf{x}$  และ  $\mathbf{y}$  มีการแจกแจงเก้าส์เชียนร่วม

$$p\begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix} = \mathcal{N}\left(\begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix} \middle| \begin{pmatrix} \mathbf{a} \\ \mathbf{b} \end{pmatrix}, \begin{pmatrix} \mathbf{A} & \mathbf{C} \\ \mathbf{C}^T & \mathbf{B} \end{pmatrix}\right),$$

แล้วการแจกแจงขอบ (marginal) และการแจกแจงเมื่อให้ (conditional) ของ  $\mathbf{x}$  และ  $\mathbf{y}$  จะเป็น

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x}|\mathbf{a}, \mathbf{A})$$

$$p(\mathbf{y}) = \mathcal{N}(\mathbf{y}|\mathbf{b}, \mathbf{B})$$

$$p(\mathbf{x}|\mathbf{y}) = \mathcal{N}(\mathbf{x}|\mathbf{a} + \mathbf{C}\mathbf{B}^{-1}(\mathbf{y} - \mathbf{b}), \mathbf{A} - \mathbf{C}\mathbf{B}^{-1}\mathbf{C}^T)$$

$$p(\mathbf{y}|\mathbf{x}) = \mathcal{N}(\mathbf{y}|\mathbf{b} + \mathbf{C}^T\mathbf{A}^{-1}(\mathbf{x} - \mathbf{a}), \mathbf{B} - \mathbf{C}^T\mathbf{A}^{-1}\mathbf{C})$$

ถ้าตัวแปรสุ่ม  $\mathbf{x}$  และ  $\mathbf{y}$  มีการแจกแจงความน่าจะเป็นแบบเกาส์เชียน

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x}|\mathbf{m}, \mathbf{P})$$
$$p(\mathbf{y}|\mathbf{x}) = \mathcal{N}(\mathbf{y}|\mathbf{Hx} + \mathbf{u}, \mathbf{R}),$$

แล้วการแจกแจงร่วมของ  $\mathbf{x}$  และ  $\mathbf{y}$  จะเป็นแบบเกาส์เชียนด้วย

$$p\begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix} = \mathcal{N}\left(\begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix} \middle| \begin{pmatrix} \mathbf{m} \\ \mathbf{Hm} + \mathbf{u} \end{pmatrix}, \begin{pmatrix} \mathbf{P} & \mathbf{PH}^T \\ \mathbf{HP} & \mathbf{HPH}^T + \mathbf{R} \end{pmatrix}\right)$$

## ตัวกรองของเบย์แบบต่อเนื่อง (Continuous Bayes filter)

ตัวกรองของเบย์ขยายไปสู่ตัวแปรสถานะและหลักฐานต่อเนื่อง  $\mathbf{X}_t$  และ  $\mathbf{E}_t$

ผลรวมจะถูกแทนที่ด้วยปริพันธ์ และพังก์ชันมวลความน่าจะเป็นจะถูกแทนที่ด้วยพังก์ชันความพนันแน่นของความน่าจะเป็น ทำให้ได้ความสัมพันธ์แบบเบย์เรียนรู้

$$p(\mathbf{x}_{t+1}|\mathbf{e}_{1:t+1}) \propto p(\mathbf{e}_{t+1}|\mathbf{x}_{t+1}) \int p(\mathbf{x}_{t+1}|\mathbf{x}_t)p(\mathbf{x}_t|\mathbf{e}_{1:t})d\mathbf{x}_t,$$


โดยที่ค่าคงที่การทำให้เป็นบวกทั้งหมดคือ

$$Z = \int p(\mathbf{e}_{t+1}|\mathbf{x}_{t+1})p(\mathbf{x}_{t+1}|\mathbf{e}_{1:t})d\mathbf{x}_{t+1}$$

## ตัวกรองค่าลามาน (Kalman filter)


ตัวกรองค่าลามาน เป็นกรณีพิเศษของตัวกรองของเบนซ์ ซึ่งสมมติว่า:

- ค่าก่อนเป็นแบบเกาส์เซียน
- แบบจำลองการเปลี่ยนสถานะเป็นแบบเกาส์เซียนเชิงเส้น
- แบบจำลองเชิงเชอร์เป็นแบบเกาส์เซียนเชิงเส้น



$$p(\mathbf{x}_{t+1}|\mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t+1}|\mathbf{A}\mathbf{x}_t + \mathbf{b}, \Sigma_x)$$

แบบจำลองการเปลี่ยนสถานะ



$$p(\mathbf{e}_t|\mathbf{x}_t) = \mathcal{N}(\mathbf{e}_t|\mathbf{C}\mathbf{x}_t + \mathbf{d}, \Sigma_e)$$

แบบจำลองเชิงเชอร์

## การกรองการแจกแจงแบบเกาส์เซียน

- ขั้นตอนการทำนาย:

ถ้าการแจกแจง  $p(\mathbf{x}_t | \mathbf{e}_{1:t})$  เป็นแบบเกาส์เซียน และแบบจำลองการเปลี่ยนสถานะ  $p(\mathbf{x}_{t+1} | \mathbf{x}_t)$  เป็นแบบเกาส์เซียนเชิงเส้น แล้วการแจกแจงที่ทำนายล่วงหน้าหนึ่งขั้นตอนที่ได้จาก

$$p(\mathbf{x}_{t+1} | \mathbf{e}_{1:t}) = \int p(\mathbf{x}_{t+1} | \mathbf{x}_t) p(\mathbf{x}_t | \mathbf{e}_{1:t}) d\mathbf{x}_t$$

ก็จะเป็นการแจกแจงแบบเกาส์เซียนเช่นกัน

- ขั้นตอนการอัปเดต:

ถ้าการทำนาย  $p(\mathbf{x}_{t+1} | \mathbf{e}_{1:t})$  เป็นแบบเกาส์เซียน และแบบจำลองเชื้อครัวร์  $p(\mathbf{e}_{t+1} | \mathbf{x}_{t+1})$  เป็นแบบเกาส์เซียนเชิงเส้น แล้วหลังจากการปรับเงื่อนไขด้วยหลักฐานใหม่ การแจกแจงที่อัปเดตแล้ว

$$p(\mathbf{x}_{t+1} | \mathbf{e}_{1:t+1}) \propto p(\mathbf{e}_{t+1} | \mathbf{x}_{t+1}) p(\mathbf{x}_{t+1} | \mathbf{e}_{1:t})$$

ก็จะเป็นการแจกแจงแบบเกาส์เซียนเช่นกัน

ดังนั้น สำหรับตัวกรองค่าลามาน  $p(\mathbf{x}_t | \mathbf{e}_{1:t})$  จะเป็นการแจกแจงปกติหลายตัวแปร  $\mathcal{N}(\mathbf{x}_t | \mu_t, \Sigma_t)$  สำหรับทุกค่า  $t$

- การกรองจะลดรูปลงเหลือเพียงการคำนวณพารามิเตอร์  $\mu_t$  และ  $\Sigma_t$
- ในทางตรงกันข้าม สำหรับกระบวนการทั่วไป (ที่ไม่ใช่เชิงเส้น, ไม่ใช่เกลล์เซียน) คำอธิบายของการแจกแจงภายหลังจะเติบโตอย่างไม่มีขีดจำกัด เมื่อ  $t \rightarrow \infty$

## ตัวอย่าง 1 มิติ

การเดินสุ่มแบบเกาล์เซียน (Gaussian random walk):

- ค่าก่อนแบบเกาล์เซียน:

$$p(x_0) = \mathcal{N}(x_0 | \mu_0, \sigma_0^2)$$

- แบบจำลองการเปลี่ยนสถานะจะเพิ่มการรบกวนแบบสุ่มที่มีความแปรปรวนคงที่:

$$p(x_{t+1} | x_t) = \mathcal{N}(x_{t+1} | x_t, \sigma_x^2)$$

- แบบจำลองเชิงเชอร์ให้ค่าการวัดที่มีสัญญาณรบกวนแบบเกาล์เซียนที่มีความแปรปรวนคงที่:

$$p(e_t | x_t) = \mathcal{N}(e_t | x_t, \sigma_e^2)$$


การแจกแจงที่ทำนายล่วงหน้าหนึ่งขั้นตอนคือ

$$\begin{aligned} p(x_1) &= \int p(x_1|x_0)p(x_0)dx_0 \\ &\propto \int \exp\left(-\frac{1}{2}\frac{(x_1 - x_0)^2}{\sigma_x^2}\right) \exp\left(-\frac{1}{2}\frac{(x_0 - \mu_0)^2}{\sigma_0^2}\right) dx_0 \\ &\propto \int \exp\left(-\frac{1}{2}\frac{\sigma_0^2(x_1 - x_0)^2 + \sigma_x^2(x_0 - \mu_0)^2}{\sigma_0^2\sigma_x^2}\right) dx_0 \\ &\dots \text{ (จัดรูปโดยการทำให้เป็นกำลังสองสมบูรณ์)} \\ &\propto \exp\left(-\frac{1}{2}\frac{(x_1 - \mu_0)^2}{\sigma_0^2 + \sigma_x^2}\right) \\ &= \mathcal{N}(x_1|\mu_0, \sigma_0^2 + \sigma_x^2) \end{aligned}$$

โปรดทราบว่าผลลัพธ์เดียวกันนี้สามารถหาได้โดยใช้เอกลักษณ์ของแบบจำลองเก้าอี้ยนแทน

สำหรับขั้นตอนการอัปเดต เราต้องปรับเงื่อนไขตามการสังเกต ณ เวลาแรก:

$$\begin{aligned} p(x_1|e_1) &\propto p(e_1|x_1)p(x_1) \\ &\propto \exp\left(-\frac{1}{2}\frac{(e_1 - x_1)^2}{\sigma_e^2}\right) \exp\left(-\frac{1}{2}\frac{(x_1 - \mu_0)^2}{\sigma_0^2 + \sigma_x^2}\right) \\ &\propto \exp\left(-\frac{1}{2}\frac{\left(x_1 - \frac{(\sigma_0^2 + \sigma_x^2)e_1 + \sigma_e^2\mu_0}{\sigma_0^2 + \sigma_x^2 + \sigma_e^2}\right)^2}{\frac{(\sigma_0^2 + \sigma_x^2)\sigma_e^2}{\sigma_0^2 + \sigma_x^2 + \sigma_e^2}}\right) \\ &= \mathcal{N}\left(x_1 \middle| \frac{(\sigma_0^2 + \sigma_x^2)e_1 + \sigma_e^2\mu_0}{\sigma_0^2 + \sigma_x^2 + \sigma_e^2}, \frac{(\sigma_0^2 + \sigma_x^2)\sigma_e^2}{\sigma_0^2 + \sigma_x^2 + \sigma_e^2}\right) \end{aligned}$$



โดยสรุป สมการอัปเดตเมื่อมีหลักฐานใหม่  $e_{t+1}$  คือ:

$$\mu_{t+1} = \frac{(\sigma_t^2 + \sigma_x^2)e_{t+1} + \sigma_e^2\mu_t}{\sigma_t^2 + \sigma_x^2 + \sigma_e^2}$$

$$\sigma_{t+1}^2 = \frac{(\sigma_t^2 + \sigma_x^2)\sigma_e^2}{\sigma_t^2 + \sigma_x^2 + \sigma_e^2}$$

เราสามารถตีความ การคำนวณค่าเฉลี่ยใหม่  $\mu_{t+1}$  ว่าเป็นเพียงค่าเฉลี่ยถ่วงน้ำหนักของการสังเกตใหม่  $e_{t+1}$  และค่าเฉลี่ยเก่า  $\mu_t$

- ถ้าการสังเกตไม่น่าเชื่อถือ แล้ว  $\sigma_e^2$  จะมีค่ามาก และเราจะให้ความสำคัญกับค่าเฉลี่ยเก่ามากกว่า
- ถ้าการสังเกตน่าเชื่อถือ แล้วเราจะให้ความสำคัญกับหลักฐานมากกว่าและให้ความสำคัญกับค่าเฉลี่ยเก่าน้อยลง
- ถ้าค่าเฉลี่ยเก่าไม่น่าเชื่อถือ ( $\sigma_t^2$  มีค่ามาก) หรือกระบวนการการคาดเดาได้ยากมาก ( $\sigma_x^2$  มีค่ามาก) แล้วเราจะให้ความสำคัญกับการสังเกตมากกว่า

## การอัปเดตค่าลามานท์ไว้ไป

การสืบหอดเดียวกันนี้ขยายไปสู่การแจกแจงปกติหลายตัวแปร

สมมติว่าแบบจำลองการเปลี่ยนสถานะและเช็นเซอร์เป็น

$$\begin{aligned} p(\mathbf{x}_{t+1}|\mathbf{x}_t) &= \mathcal{N}(\mathbf{x}_{t+1}|\mathbf{F}\mathbf{x}_t, \Sigma_{\mathbf{x}}) \\ p(\mathbf{e}_t|\mathbf{x}_t) &= \mathcal{N}(\mathbf{e}_t|\mathbf{H}\mathbf{x}_t, \Sigma_{\mathbf{e}}), \end{aligned}$$

เราจะได้สมการอัปเดตทั่วไปดังนี้:

$$\begin{aligned} \mu_{t+1} &= \mathbf{F}\mu_t + \mathbf{K}_{t+1}(\mathbf{e}_{t+1} - \mathbf{H}\mathbf{F}\mu_t) \\ \Sigma_{t+1} &= (\mathbf{I} - \mathbf{K}_{t+1}\mathbf{H})(\mathbf{F}\Sigma_t\mathbf{F}^T + \Sigma_x) \\ \mathbf{K}_{t+1} &= (\mathbf{F}\Sigma_t\mathbf{F}^T + \Sigma_x)\mathbf{H}^T(\mathbf{H}(\mathbf{F}\Sigma_t\mathbf{F}^T + \Sigma_x)\mathbf{H}^T + \Sigma_e)^{-1} \end{aligned}$$

โดยที่  $\mathbf{K}_{t+1}$  คือเมตริกซ์เกนค่าลามาน (Kalman gain matrix)

โปรดทราบว่า  $\Sigma_{t+1}$  และ  $\mathbf{K}_{t+1}$  ไม่ขึ้นอยู่กับหลักฐาน ดังนั้นจึงสามารถคำนวณแบบออนไลน์ได้


สมการเหล่านี้มีความหมายที่เข้าใจได้ง่าย


พิจารณา การอัปเดตสำหรับค่าประมาณสถานะเฉลี่ย  $\mu_{t+1}$

- พจน์  $\mathbf{F}_{\mu_t}$  คือสถานะที่ทำนาย ณ เวลา  $t + 1$
- ดังนั้น  $\mathbf{HF}_{\mu_t}$  คือการสังเกตที่ทำนาย
- ดังนั้น พจน์  $\mathbf{e}_{t+1} - \mathbf{HF}_{\mu_t}$  แทนข้อผิดพลาดใน การสังเกตที่ทำนาย
- สิ่งนี้ถูกคูณด้วย  $\mathbf{K}_{t+1}$  เพื่อแก้ไขสถานะที่ทำนาย; ดังนั้น  $\mathbf{K}_{t+1}$  คือตัวชี้วัดว่าจะให้ความสำคัญกับการสังเกต ใหม่เทียบกับ การทำนายมากน้อยเพียงใด

## คอมพิวเตอร์นำทางของอะ波โลโล

คอมพิวเตอร์นำทางของอะ波โลโล (Apollo Guidance Computer) ใช้ตัวกรองค่าลามานเพื่อประมาณตำแหน่งของยานอวกาศ ตัวกรองค่าลามานถูกใช้เพื่อร่วมข้อมูลใหม่เข้ากับการวัดตำแหน่ง ในอดีตเพื่อสร้างค่าประมาณตำแหน่งที่ดีที่สุดของยานอวกาศ





สาขาวิชา: การติดตามวัตถุในอวกาศโดยใช้ตัวกรองคามมาน

## การดูดกลืนข้อมูลสำหรับการพยากรณ์อากาศ

ในการพยากรณ์อากาศ การกรองถูกใช้เพื่อรวมการสังเกตการณ์บรรยากาศเข้ากับแบบจำลองเชิงตัวเลขเพื่อประมาณสถานะปัจจุบันของมัน ลิ่งนี้เรียกว่า **การดูดกลืนข้อมูล** (data assimilation)

จากนั้น แบบจำลองจะถูกใช้เพื่อทำนายสถานะในอนาคตของบรรยากาศ

20 YEARS OF 4DVAR



## การดูดกลืนข้อมูลสำหรับการพยากรณ์อากาศ



ในการพยากรณ์อากาศ การกรองถูกใช้เพื่อรวมการสังเกตการณ์บรรยากาศเข้ากับแบบจำลองเชิงตัวเลขเพื่อประมาณสถานะปัจจุบันของมัน ลิ่งนี้เรียกว่า **การดูดกลืนข้อมูล** (data assimilation)

จากนั้น แบบจำลองจะถูกใช้เพื่อทำนายสถานะในอนาคตของบรรยากาศ

20 YEARS OF 4DVAR



## เครือข่ายเบย์แบบพลวัต (Dynamic Bayesian networks)




เครือข่ายเบย์แบบพลวัต (Dynamic Bayesian networks - DBNs) สามารถใช้ในการติดตามตัวแปรหลายตัวเมื่อเวลาผ่านไป โดยใช้แหล่งข้อมูลหลายแหล่ง แนวคิดคือ:


- ทำข้าโครงสร้างเครือข่ายเบย์คงที่ในแต่ละช่วงเวลา  $t$
- ตัวแปรจากเวลา  $t$  ขึ้นอยู่กับตัวแปรจาก  $t - 1$

DBNs เป็นการขยายแนวคิดของ HMMs และตัวกรองความман

## การประยุกต์ใช้: การเฝ้าระวังในห้องไอซีयู



## การอนุมานที่แม่นยำ (Exact inference)



คลี่เครือข่ายออกตามเวลาและใช้อัลกอริทึมการอนุมานที่แม่นยำไดๆ (เช่น การกำจัดตัวแปร)

- ปัญหา: ค่าใช้จ่ายในการอนุมานสำหรับการอัปเดตแต่ละครั้งจะเพิ่มขึ้นตาม  $t$
- การกรองแบบรวมยอด (Rollup filtering): เพิ่มช่วงเวลา  $t+1$  และภาพรวมของช่วงเวลา  $t$  โดยใช้การกำจัดตัวแปร
  - ปัจจัยที่ใหญ่ที่สุดคือ  $O(d^{n+k})$  และค่าใช้จ่ายในการอัปเดตห้องด้วยชั้นตอนคือ  $O(nd^{n+k})$
  - ตีกว่า HMMs ซึ่งเป็น  $O(d^{2n})$  แต่ยังคงไม่สามารถทำได้จริงสำหรับตัวแปรจำนวนมาก

## ตัวกรองอนุภาค (Particle filter)

แนวคิดพื้นฐาน:


- รักษาประชากรจำกัดของตัวอย่าง เรียกว่า อนุภาค (particles)
  - การแสดงความเชื่อของเราคือรายการของอนุภาค  $N$  ตัว
- ตรวจสอบให้แน่ใจว่าอนุภาคติดตามบริเวณที่มีความน่าจะเป็นสูงของปริภูมิสถานะ
- ทิ้งตัวอย่างที่มีน้ำหนักต่ำมากตามหลักฐาน
- ทำข้าตัวอย่างที่มีน้ำหนักสูง

วิธีนี้สามารถปรับขนาดให้เข้ากับมิติที่สูงได้!




## วงจรการอัปเดต


Elapsed



Weight



Resample



Particles:

(3,3)  
(2,3)  
(3,3)  
(3,2)  
(3,3)  
(3,2)  
(1,2)  
(3,3)  
(3,3)  
(2,3)

Particles:

(3,2)  
(2,3)  
(3,2)  
(3,1)  
(3,3)  
(3,2)  
(1,3)  
(2,3)  
(3,2)  
(2,2)

Particles:

(3,2) w=.9  
(2,3) w=.2  
(3,2) w=.9  
(3,1) w=.4  
(3,3) w=.4  
(3,2) w=.9  
(1,3) w=.1  
(2,3) w=.2  
(3,2) w=.9  
(2,2) w=.4

(New) Particles:

(3,2)  
(2,2)  
(3,2)  
(2,3)  
(3,3)  
(3,2)  
(1,3)  
(2,3)  
(3,2)  
(3,2)


```

function PARTICLE-FILTERING(e,  $N$ ,  $dbn$ ) returns a set of samples for the next time step
  inputs: e, the new incoming evidence
     $N$ , the number of samples to be maintained
     $dbn$ , a DBN with prior  $\mathbf{P}(\mathbf{X}_0)$ , transition model  $\mathbf{P}(\mathbf{X}_1|\mathbf{X}_0)$ , sensor model  $\mathbf{P}(\mathbf{E}_1|\mathbf{X}_1)$ 
  persistent:  $S$ , a vector of samples of size  $N$ , initially generated from  $\mathbf{P}(\mathbf{X}_0)$ 
  local variables:  $W$ , a vector of weights of size  $N$ 

  for  $i = 1$  to  $N$  do
     $S[i] \leftarrow$  sample from  $\mathbf{P}(\mathbf{X}_1 | \mathbf{X}_0 = S[i])$  /* step 1 */
     $W[i] \leftarrow \mathbf{P}(\mathbf{e} | \mathbf{X}_1 = S[i])$  /* step 2 */
     $S \leftarrow$  WEIGHTED-SAMPLE-WITH-REPLACEMENT( $N$ ,  $S$ ,  $W$ ) /* step 3 */
  return  $S$ 

```

## การหาตำแหน่งหุ่นยนต์ (Robot localization)



(ดูการสาธิต)

## สรุป

- แบบจำลองเชิงเวลา ใช้ตัวแปรสถานะและเซ็นเซอร์ที่ทำซ้ำเมื่อเวลาผ่านไป
  - จุดประสงค์คือเพื่อรักษาสถานะความเชื่อมเมื่อเวลาผ่านไปและเมื่อฟีลัคฐานมากขึ้น
- ข้อสมมติของมาร์คอฟและความนิ่งหมายความว่าเราต้องระบุเพียง
  - แบบจำลองการเปลี่ยนสถานะ  $P(\mathbf{X}_{t+1}|\mathbf{X}_t)$
  - แบบจำลองเซ็นเซอร์  $P(\mathbf{E}_t|\mathbf{X}_t)$
- งานการอนุมานรวมถึงการกรอง, การทำนาย, การปรับให้เรียบ และการค้นหาลำดับที่น่าจะเป็นไปได้มากที่สุด
- อัลกอริธึมตัวกรองทั้งหมดมีพื้นฐานมาจากแนวคิดหลักของ
  - การจ่ายภาพสถานะความเชื่อมปัจจุบันผ่านแบบจำลองการเปลี่ยนสถานะ
  - การอัปเดตการทำนายตามหลักฐานใหม่

The end.